

Progetto Finale

Introduzione alla Data Science, AA 2025/2026

Docenti: L. Calatroni, L. Rosasco, **Tutor:** G. Meanti

Nel progetto finale dovrai affrontare un tipico problema di data science, sviluppando la pipeline dall'inizio alla fine. Ti verrà fornito un dataset di prezzi delle case basato su informazioni di vendita in California. Insieme ai prezzi, i dati contengono informazioni sulle aree in cui sono avvenute le vendite: popolazione, reddito, dimensioni delle case (determinate dal numero di stanze) e posizione. Dovrai eseguire una prima fase di pulizia dei dati e analizzare le variabili presenti, cercando correlazioni e informazioni rilevanti. Successivamente utilizzerai le tecniche viste a lezione per implementare gli algoritmi di apprendimento studiati al fine di prevedere una classe di appartenenza delle case su un insieme test che non verrà fornito. Ti forniremo infatti una parte del dataset completo, che ti servirà per il training dei modelli. Il resto verrà mantenuto come un vero *hold out* set per valutare gli algoritmi dopo la scadenza della consegna. Per ottenere buone prestazioni su questo insieme, dovrai eseguire correttamente la selezione del modello utilizzando la cross-validation. Assicurati di non fare overfitting sul training set! L'obiettivo è ottenere delle buone previsioni dei prezzi delle case sul test set.

La consegna finale prevede:

1. un notebook `.ipynb` commentato in forma di report che descriva il tuo lavoro, guidato dalle domande riportate sotto;
2. un **file Python eseguibile** con cui valuteremo l'accuratezza del tuo miglior modello.

Tramite l'uso della libreria `scikit-learn`, dovrai implementare 4 algoritmi visti a lezione per un problema di **classificazione multi classe** (minimizzazione del rischio empirico con loss quadratica e regressione logistica, k-NN e alberi decisionali). Hai la facoltà di utilizzare un quinto algoritmo di tua scelta eventualmente non visto a lezione, ma di tuo interesse.

Integrità accademica Il progetto deve essere svolto autonomamente. Durante la valutazione potremo porre domande specifiche sul codice e sulle scelte progettuali per verificare che il lavoro sia stato effettivamente realizzato dagli studenti. L'utilizzo di strumenti automatici o assistenti basati su intelligenza artificiale per generare codice senza una piena comprensione non è consentito e potrà comportare penalizzazioni.

1 Descrizione dei dati

Il dataset consiste di 10320 campioni e 14 variabili:

1. `longitude`, `latitude`: posizione geografica dell'area dove si trova la casa.
2. `housing_median_age`: età mediana delle case vendute.
3. `total_rooms`, `total_bedrooms`: numero totale di stanze e camere da letto nell'area di vendita.
4. `population`: popolazione residente nell'area.
5. `households`: numero di nuclei familiari.
6. `median_income`: reddito mediano espresso in unità di \$100 000.
7. `distance_to_coast`, `distance_to_LA`, `distance_to_sandiego`, `distance_to_sanjose`, `distance_to_sanfrancisco`: distanza dalla costa e dalle principali città della California.
8. `median_house_value`: valore discreto del prezzo delle case. Ogni valore è una classe ottenuta tramite raggruppamento in range (binning) dei prezzi corrispondenti.
 - 0: tra \$0 e \$100 000
 - 1: tra \$100 000 e \$150 000
 - 2: tra \$150 000 e \$200 000
 - 3: tra \$200 000 e \$300 000
 - 4: oltre \$300 000

Nota: i prezzi risalgono al 1999.

2 Struttura del notebook

Ti consigliamo di suddividere il notebook seguendo la seguente struttura. Le domande poste hanno il fine di guidare l'analisi.

1. Caricamento dati

- Puoi usare `pandas` per leggere file CSV
- Quali variabili sono categoriali e quali numeriche?
- Separa la variabile target dalle features

2. Visualizzazione dei dati

- Ci sono valori mancanti? Quanti e su quali variabili? Come li puoi gestire?
- Il target richiede regressione o classificazione? Se classificazione, in quante classi? Le classi sono in numero bilanciato?
- Esistono correlazioni tra le variabili e il target e tra le variabili stesse? Formula ipotesi e verifica.

3. **Codifica della variabile target** A seconda dell'algoritmo il modo corretto di rappresentare la variabile target può cambiare. Gli algoritmi di classificazione binaria visti a lezione rendono necessario trovare un modo alternativo di gestire dati multi-classe. Un modo comune è di effettuare classificazione one-vs-all (anche chiamate one-vs-rest): vengono allenati k classificatori binari (dove k è il numero di classi) in cui ognuno deve distinguere una classe da tutte le altre. Al momento di effettuare una predizione poi, ognuno dei classificatori binari darà una certa confidenza che l'esempio appartenga alla propria classe. La predizione finale è quella del classificatore con la confidenza maggiore. Tuttavia, altri algoritmi invece possono gestire molteplici classi in maniera automatica, quindi non è necessario effettuare la codifica one-vs-all.

- Per ogni algoritmo analizzato determina la codifica più appropriata della variabile target. Presta attenzione anche al significato della variabile di prezzo per decidere il modo migliore di affrontare il problema.

4. **Cross validation**

- Imposta una procedura di validazione

5. **Classificazione tramite minimizzazione del rischio empirico con loss quadratica**

- Esegui il fit
- Interpreta i coefficienti ottenuti
- Valuta le prestazioni

6. **Classificazione tramite minimizzazione del rischio empirico con loss logistica**

- Esegui il fit
- Analizza l'effetto del parametro di regolarizzazione
- Quali classi sono più difficili da predire?

7. **k-NN**

- Esegui il fit
- Studia l'errore al variare di k valutando se esiste un valore ottimale
- Commenta complessità e accuratezza

8. **Alberi decisionali**

- Analizza l'effetto dei parametri dell'albero (ad esempio profondità massima, numero minimo di campioni per foglia) sulle prestazioni del modello.
- Quali variabili risultano più importanti secondo il modello? I risultati sono coerenti con l'analisi delle correlazioni?

9. (Opzionale) **Un algoritmo a scelta**

10. **Conclusioni**

Hint: Assicurati che le predizioni finali siano espresse come etichette di classe discrete!

3 Valutazione sul set di test

Valuteremo il tuo modello sulla base delle prestazioni su un dataset mai visto. Questo consente di misurare la capacità di generalizzazione del modello. Dovrai consegnare uno script Python che addestra il modello migliore tra quelli testati e produce predizioni su nuovi dati.

Il file deve chiamarsi seguendo la tua matricola UniGe, ad esempio `S4000000.py`. Al momento di effettuare la nostra valutazione eseguiremo il file con la seguente riga di comando, dove il file di train e' lo stesso dataset a vostra disposizione (quindi contiene valori mancanti!) mentre il file di test segue la stessa struttura ma non contiene valori mancanti.

```
python S4000000.py --train=houses_data.csv --test=houses_test.csv
```

Lo script deve salvare un file `S40000000.txt` nella stessa cartella dello script contenente una predizione per riga. Segue un esempio di script (senza addestramento del modello).

```
import argparse
import pandas as pd
import numpy as np

def run_model(train_file, test_file):
    # Load data
    train_df = pd.read_csv(train_file)
    test_df = pd.read_csv(test_file)

    # Insert your model training and prediction code here
    predictions = np.zeros(len(test_df))

    # Save predictions to file, one per line
    with open("S4000000.txt", "w") as fh:
        for pred in predictions:
            fh.write(f"{pred}\n")

if __name__ == "__main__":
    parser = argparse.ArgumentParser()
    parser.add_argument("--train", type=str, required=True)
    parser.add_argument("--test", type=str, required=True)
    args = parser.parse_args()
    run_model(args.train, args.test)
```

Utilizzo librerie: Fai attenzione alle librerie che utilizzi: sul nostro computer di test saranno disponibili solo `scikit-learn`, `pandas`, `numpy` e la libreria standard. Se ritieni di avere davvero bisogno di una libreria esterna, scrivici e valuteremo la richiesta. Se non riusciremo a eseguire il tuo script, oppure se l'addestramento fallirà o richiederà un tempo irragionevole, non ti verrà assegnato alcun punto.